

Aorta AI

חיזוי סיכון לסיבוכים לאחר ניתוח אבי העורקים

באמצעות שיטות של Machine Learning

דוח פרויקט גמר

מגשים: ענאל מימון ודניאל בריך

לקוח: Dr. Maysam Shehab

מנחה: Dr. Sharon Yalov-Handzel

מוסד לימודים: מכללת אפקה

תאריך: יוני 2026

Data provided in collaboration with Dr. Maysam Shehab- Senior Vascular & Endovascular Surgeon, Aortic Fellow, Uppsala University Hospital

תוכן עניינים

2	תוכן עניינים
3	1. מבוא
3	2. עיבוד מקדים של הנתונים (Data Preprocessing)
3	2.1 צמצום מספר העמודות
3	2.2 ניקוי וטיוב הנתונים
4	3. משתני המטרה (Targets)
4	3.1 סיבוכים מוקדמים (Early Complications)
4	3.2 סיבוכים בטווח הארוך (Long-Term, עד 36 חודשים)
4	4. מתודולוגיה
4	4.1 המודלים והשיטות
5	4.2 מדדי הערכה (Evaluation Metrics)
6	5. תוצאות לפי משתנה מטרה
6	5.1 Early Death — (מוות מוקדם)
9	5.2 Early MACCE — (אירועים לבביים ומוחיים חמורים)
12	5.3 Early CAD — (מחלת עורקים כליליים)
14	5.4 Early CHF — (אי-ספיקת לב)
16	5.5 Early Paraplegia — (פרהפלגיה)
18	5.6 Early Reintervention — (התערבות חוזרת מוקדמת)
20	5.7 Early Stroke — (שבץ מוקדם)
21	5.8 Death up to 36 Months — (מוות עד 36 חודשים)
23	5.9 Reintervention up to 36 Months — (התערבות חוזרת עד 36 חודשים)
25	6. סיכום והשוואה
26	7. מסקנות

1. מבוא

פרויקט Aorta AI עוסק בבניית מודלים של למידת מכונה על נתונים רפואיים של מטופלים עם מחלות אבי העורקים (אאורטה). מטרת הפרויקט היא לחזות את הסיכון לסיבוכים לאחר הניתוח (Post-Operative Complications), ובכך לסייע לצוות הרפואי בהערכת הסיכון של המטופלים ובקבלת החלטות מושכלות לפני ואחרי הניתוח.

בפרויקט בחרנו מספר משתני מטרה שונים (Targets) המייצגים סוגים שונים של סיכון לסיבוכים, ועבור כל אחד מהם בנינו וניסינו מספר מודלים. השתמשנו בעיקר בשני מודלים מרכזיים: XGBoost (מודל מבוסס עצי החלטה עם Boosting) ו-Cox (מודל הישרדות, Cox Proportional Hazards). עבור כל משתנה מטרה ביצענו סדרה של ניסויים במטרה לשפר את ביצועי המודל, ובהם: הוספת SMOTE לטיפול בחוסר איזון בין הקבוצות, ביצוע Tuning של היפר-פרמטרים לבחירת ההגדרות הטובות ביותר, בניית רשת נוירונים (ANN) עם שתי שכבות נסתרות, ולבסוף בניית Ensemble המשלב בין XGBoost ל-ANN. כמו כן, ברוב המודלים השתמשנו ב Cross-Validation מסוג K-Fold עם 5 קפלים (Fold) כדי להעריך את ביצועי המודל בצורה אמינה ויציבה ולהפחית את הסיכון ל Overfitting. בנוסף, בכל שלב נעזרנו ב-SHAP כדי לזהות את הפיצ'רים המשפיעים והחשובים ביותר, ובכך לשפר את ביצועי המודל ולקבל את החיזוי (Prediction) הטוב ביותר האפשרי.

בהמשך המסמך נציג את שלבי העבודה, החל מעיבוד הנתונים, דרך בניית המודלים השונים ועד להצגת המודל הטוב ביותר עבור כל משתנה מטרה בליווי הסבר קצר.

2. עיבוד מקדים של הנתונים (Data Preprocessing)

נקודת המוצא של הפרויקט הייתה מערך נתונים אמיתי מקופת חולים כללית הכולל 203 פיצ'רים (עמודות) ו-2,423 רשומות (מטופלים). לפני בניית המודלים ביצענו תהליך מעמיק של ניקוי וצמצום הנתונים, שמטרתו להשאיר אך ורק את המידע הרלוונטי והאיכותי ביותר.

2.1 צמצום מספר העמודות

1. הסרנו את כל העמודות שבהן היו יותר מ-20% ערכים ריקים, וכן עמודות שכל הערכים בהן היו ייחודיים (Unique Value) ולכן לא תרמו מידע מבחין. שלב זה הסיר 101 עמודות.
 2. הסרנו ידנית 41 עמודות שלא נשאו ערך חיזוי (כגון מזהים id ועמודות דומות).
 3. הסרנו 13 עמודות נוספות בשל מולטיקולינאריות זה אומר שקיים קשר חזק מדי בין לבין פיצ'רים אחרים.
- בסיכום התהליך התחלנו עם 203 עמודות וסיימנו עם 48 עמודות. מערך הנתונים הנקי (Cleaned Data) כולל אם כן 48 עמודות ו-2,423 רשומות.

2.2 ניקוי וטיפול בנתונים

4. במערך הנתונים המקורי הופיעו מושגים רבים ושונים שכולם ייצגו למעשה ערך חסר (Null) למשל NaN, רווחים ריקים, נקודות ועוד. אחדנו את כולם לערך חסר אחיד וברור.
5. העמודות שנותרו עם פחות מ-20% חסרים השלמנו עם הממוצע או החציון.
6. שינינו מספר עמודות לקידוד קטגוריאל (Categorical Encoding) למשל עמודת הסוציו-אקונומי קודד לערכים מסודרים (socio = 1, 2, 3, 4, 5).

7. ביצענו One-Hot Encoding על משתנים קטגוריאליים, לדוגמה המשתנה Gender (מין). לאחר ה-One-Hot Encoding מספר העמודות גדל מ-48 ל-65 עמודות.

3. משתני המטרה (Targets)

בפרויקט הגדרנו שתי משפחות של משתני מטרה, בהתאם לאופי הסיבוך ולטווח הזמן שלו:

3.1 סיבוכים מוקדמים (Early Complications)

סיבוכים המופיעים בתקופה עד 30 יום אחרי הניתוח. עבור משתנים אלו השתמשנו בסיווג בינארי באמצעות XGBoost, ANN ו-Ensemble:

- **Early Death**: מוות מוקדם של עד 30 יום אחרי הניתוח.
- **Early MACCE**: אירועים קרדיווסקולריים ומוחיים.
- **Early CAD**: מחלת עורקים כליליים (Coronary Artery Disease).
- **Early CHF**: אי-ספיקת לב (Congestive Heart Failure).
- **Early Paraplegia**: שיתוק גפיים תחתונות, פרהפלגיה.
- **Early Reintervention**: התערבות/ניתוח חוזר בטווח המוקדם.

3.2 סיבוכים בטווח הארוך (Long-Term, עד 36 חודשים)

עבור משתנים אלו השתמשנו במודל הישרדות Cox, המתאים לחיזוי הסתברות לאירוע לאורך זמן:

- **Death up to 36 Months**: מוות בתוך 3 שנים מהניתוח.
- **Reintervention up to 36 Months**: התערבות/ניתוח חוזר בתוך 3 שנים מהניתוח.

4. מתודולוגיה

בפרק זה נסביר בקצרה את הכלים והשיטות שבהם השתמשנו לאורך הפרויקט.

4.1 המודלים והשיטות

- **XGBoost** — אלגוריתם מבוסס עצי החלטה עם Gradient Boosting. בנינו עצים בזה אחר זה, כאשר כל עץ מתקן את שגיאות קודמיו. מודל חזק ויעיל לנתונים טבלאיים.
- **Cox Proportional Hazards** — מודל הישרדות (Survival) המעריך את הסיכון לאירוע כפונקציה של זמן ושל הפיצ'רים, ומתאים למשתני המטרה בטווח הארוך.
- **SMOTE (Synthetic Minority Over-sampling Technique)** — שיטה ליצירת דגימות סינתטיות של הקבוצה המיעוטית, לטיפול בחוסר האיזון בין מטופלים עם ובלי סיבוך.
- **Hyperparameter Tuning** — חיפוש שיטתי אחר ההיפר-פרמטרים הטובים ביותר (כגון עומק העץ, קצב הלמידה) לשיפור ביצועי המודל.
- **K-Fold Cross-Validation (5-Fold)** — שיטת אימות שבה מחלקים את הנתונים ל-5 חלקים שווים; בכל איטרציה המודל מתאמן על 4 חלקים ונבדק על החלק החמישי, וכך כל הנתונים משמשים גם לאימון וגם לבדיקה. השתמשנו בשיטה זו ברוב המודלים כדי לקבל הערכת ביצועים יציבה ואמינה.
- **ANN (רשת נוירונים מלאכותית)** — רשת עם שתי שכבות נסתרות (Hidden Layers) שנבנתה כדי ללכוד קשרים לא-ליניאריים בין הפיצ'רים.

- **Ensemble** — שילוב של XGBoost ו-ANN, המנצל את היתרונות של שני המודלים יחד כדי לקבל חיזוי יציב ומדויק יותר.
- **SHAP (Sapley Additive exPlanations)** — שיטת הסבר (Explainability) המודדת את התרומה של כל פיצ'ר לחיזוי, ומשמשת לבחירת הפיצ'רים החשובים ביותר.

4.2 מדדי הערכה (Evaluation Metrics)

להערכת המודלים התבססנו על שלושה מדדים מרכזיים, ולצדם מדדים משלימים שנועדו לתת תמונה מלאה יותר.

המדדים המרכזיים:

- **PR-AUC (Precision-Recall AUC)** — השטח מתחת לעקומת Precision-Recall. זהו המדד המרכזי שלנו עבור משימות הסיווג, משום שהוא מתאים במיוחד לנתונים לא מאוזנים מצב שכיח אצלנו, שכן מספר המטופלים שחוו סיבוך קטן בהרבה מאלו שלא. המדד מתמקד ביכולת לזהות נכונה את הקבוצה המיעוטית (החולים בסיכון). ככל שהערך קרוב ל-1, המודל טוב יותר.
- **ROC-AUC** — השטח מתחת לעקומת ROC; מודד את יכולת ההפרדה הכוללת של המודל בין שתי הקבוצות על פני כל ספי החלטה. ערך 1 מציין הפרדה מושלמת, ו-0.5 שקול לניחוש אקראי.
- **C-index (Concordance Index עבור מודלי Cox)** — המדד המרכזי למודלי ההישרדות; מודד את ההסתברות שהמודל מדרג נכון את הסיכון בין שני מטופלים (מי יחווה את האירוע מוקדם יותר). ערך 0.5 שקול לאקראי, ו-1 מציין דירוג מושלם.

מדדים משלימים:

- **Accuracy** — אחוז התחזיות הנכונות מתוך כלל התחזיות.
- **Precision** — מתוך מי שסומנו כבעלי סיכון, כמה באמת היו בסיכון.
- **Recall (Sensitivity)** — מתוך כלל החולים בסיכון, כמה זוהו נכון. מדד קריטי בהקשר רפואי.
- **F1-Score** — ממוצע הרמוני של Precision ו-Recall.
- **AUC-ROC** — יכולת ההפרדה של המודל בין הקבוצות; ככל שקרוב ל-1 המודל טוב יותר.
- **C-index (עבור מודלי Cox)** — מדד התאמה למודלי הישרדות; מודד את היכולת לדרג נכונה את זמני האירוע.

5. תוצאות לפי משתנה מטרה

עבור כל משתנה מטרה מוצג: (א) הכנת הנתונים הספציפית למודל זה; (ב) תוצאות מודל אחר מודל, הכוללות גרפים במידת הצורך ומדדים מדויקים; (ג) המודל הנבחר בליווי הסבר. המדדים המרכזיים (PR-AUC, ROC-AUC, C-index) מודגשים בכל טבלה.

5.1 Early Death — (מוות עד 30 יום אחרי הניתוח)

א. הכנת הנתונים למודל זה

עבור מודל זה הסרנו פיצ'רים המהווים תוצאה של מה שקרה לאחר הניתוח ואינם זמינים לפני הניתוח, כדי למנוע דליפת מידע (Data Leakage). לאחר ההסרה נותרו 54 פיצ'רים שעליהם אומן המודל.

ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (Threshold 40%)

ערך (Value)	מדד (Metric)
0.2093	PR-AUC
—	ROC-AUC
0.61	Recall (class 1)
0.17	Precision (class 1)
0.27	F1-Score (class 1)
0.83	Accuracy

מטריצת בלבול: TP=76 | FP=367 | FN=49 | TN=1931

מודל 2 — XGBoost עם SMOTE (יחס 10%, 40% Threshold)

ערך (Value)	מדד (Metric)
0.2171	PR-AUC
—	ROC-AUC
0.57	Recall (class 1)
0.19	Precision (class 1)
0.28	F1-Score (class 1)
0.85	Accuracy


מטריצת בלבול: TP=71 | FP=306 | FN=54 | TN=1992

מודל 3 — ANN + SMOTE

ממד (Metric)	ערך (Value)
PR-AUC	0.2238
ROC-AUC	0.7933
Recall (class 1)	0.55
Precision (class 1)	0.22
F1-Score (class 1)	0.31
Accuracy	0.88

מטריצת בלבול: TP=69 | FP=246 | FN=56 | TN=2052

ניתוח SHAP — הפיצ'רים המשפיעים ביותר



מודל 4 — ANN + SMOTE לאחר Tuning (היפר-פרמטרים מיטביים)

ממד (Metric)	ערך (Value)
PR-AUC	0.2708
ROC-AUC	0.8138
Recall (class 1)	0.58
Precision (class 1)	0.27
F1-Score (class 1)	0.36
Accuracy	0.90

מטריצת בלבול: TP=72 | FP=199 | FN=53 | TN=2099

מודל 5 — Ensemble (XGBoost + ANN), Threshold 30%

ממד (Metric)	ערך (Value)
PR-AUC	0.2558
ROC-AUC	0.8138
Recall (class 1)	0.66
Precision (class 1)	0.21
F1-Score (class 1)	0.32
Accuracy	0.85

מטריצת בלבול: TP=83 | FP=315 | FN=42 | TN=1983

ג. המודל הנבחר

✓ המודל הנבחר

המודל 4: ANN + SMOTE לאחר Tuning

הממד המרכזי: PR-AUC = 0.2708 | ROC-AUC = 0.8138 | Accuracy = 0.90 | Recall = 0.58

הסבר: מבין חמשת המודלים, מודל זה השיג את ה-PR-AUC הגבוה ביותר ואת ה-ROC-AUC הגבוה ביותר.

כיוון ההיפר-פרמטרים של רשת הנוירונים שיפר משמעותית את הביצועים ביחס ל-XGBoost הבסיסי, תוך

שמירה על איזון טוב בין זיהוי החולים בסיכון לבין דיוק כללי גבוה.

תובנה קלינית: המודל מזהה כ-58% מהמטופלים בסיכון גבוה למוות מוקדם עוד לפני הניתוח, ובכך מאפשר לצוות הרפואי היערכות והתערבות מבעוד מועד.

5.2 Early MACCE — (אירועים לבביים ומוחיים חמורים תוך 30 יום אחרי ניתוח)

א. הכנת הנתונים למודל זה

המודל אומן על נתונים קליניים ובדיקות דם טרום-ניתוחיות בלבד, ונבדק באמצעות Stratified K-Fold על כלל הדאטהסט. לאחר אימון בסיסי בוצע ניתוח SHAP לזיהוי הפיצ'רים המשפיעים ביותר.


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (לפני SHAP)

ממד (Metric)	ערך (Value)
PR-AUC	0.176
ROC-AUC	0.702
Recall (class 1)	0.50
Precision (class 1)	0.18
F1-Score (class 1)	0.27
Accuracy	0.78

מטריצת בלבול: TP=97 | FP=434 | FN=98 | TN=1794

ניתוח SHAP — 20 הפיצ'רים המשפיעים ביותר



SHAP — early MACCE: BL_CHF, BL_CAD, Lab_albumin, Lab_Creat, BMI, Lab_Urea ועוד

מודל 2 — XGBoost (אחרי SHAP, סף מיטבי $F2=0.450$)

ממד (Metric)	ערך (Value)
PR-AUC	0.191
ROC-AUC	0.71
Recall (class 1)	0.55
Precision (class 1)	0.18
F1-Score (class 1)	0.27
Accuracy	0.76

מטריצת בלבול: TP=107 | FP=495 | FN=88 | TN=1733

מודל 3 — ANN (SMOTE 20%, שכבות נסתרות (2), רשת (64,32), Threshold 25%)

ממד (Metric)	ערך (Value)
PR-AUC	0.1457
ROC-AUC	0.6495
Recall (class 1)	—
Precision (class 1)	—
F1-Score (class 1)	—
Accuracy	—

מטריצת בלבול: TP=69 | FP=281 | FN=126 | TN=1947

מודל 4 — Ensemble (ANN + XGBoost, Threshold 0.25)

ממד (Metric)	ערך (Value)
PR-AUC	0.171
ROC-AUC	0.678
Recall (class 1)	0.48
Precision (class 1)	0.16
F1-Score (class 1)	0.24
Accuracy	0.76

מטריצת בלבול: TP=93 | FP=482 | FN=102 | TN=1746

הערה ROC-AUC (ANN): לפי 0.564 / 0.583 / 0.612 / 0.815 / 0.713. Folds. ANN=0.645-ב-Ensemble, ROC-AUC (XGBoost)=0.662, Ensemble=0.678

ג. המודל הנבחר

✓ המודל הנבחר

המודל 2: XGBoost לאחר SHAP

המדד המרכזי: $PR-AUC = 0.191$ | $ROC-AUC = 0.71$ | $Recall = 0.55$ | $Accuracy = 0.76$

הסבר: בחירת הפיצ'רים לפי SHAP נתנה את ה- $PR-AUC$ וה- $ROC-AUC$ הטובים ביותר עבור $MACCE$. הפיצ'רים שנבחרו (CHF, CAD, Albumin, Creatinine, Urea, BMI) הגיוניים מבחינה רפואית, דבר המחזק את אמינות המודל ומראה שהוא לומד קשרים קליניים אמיתיים.

תובנה קלינית: המודל מזהה כ-55% ממקרי ה- $MACCE$ ומדגיש גורמי סיכון לבביים ומטבוליים מוכרים, ככלי תומך-החלטה לפני הניתוח.

5.3 Early CAD — (מחלת עורקים כליליים תוך 30 יום אחרי ניתוח)

א. הכנת הנתונים למודל זה

המודל אומן בגרסה מלאה ובגרסה מצומצמת המבוססת על 10 הפיצ'רים המשפיעים ביותר לפי SHAP.


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (כל הפיצ'רים, Threshold 50%)

ממד (Metric)	ערך (Value)
PR-AUC	0.0564
ROC-AUC	—
Recall (class 1)	0.19
Precision (class 1)	0.06
F1-Score (class 1)	0.09
Accuracy	0.86

מטריצת בלבול: TP=16 | FP=261 | FN=68 | TN=2078

ניתוח SHAP — הפיצ'רים המשפיעים ביותר



SHAP — early CAD: BL_CAD, PRE_1, BMI, age, bmi_comheight, Lab_HB ועוד

מודל 2 — XGBoost עם 10 פיצ'רים מובילים (SHAP, Threshold 50%)

ממד (Metric)	ערך (Value)
PR-AUC	0.0594
ROC-AUC	—
Recall (class 1)	0.29
Precision (class 1)	0.08
F1-Score (class 1)	0.12
Accuracy	0.86

מטריצת בלבול: TP=24 | FP=287 | FN=60 | TN=2052

✓ המודל הנבחר

המודל 2: XGBoost לאחר SHAP ובחירה של 10 פיצ'רים המשפיעים ביותר

המדד המרכזי: $PR-AUC = 0.0594$ | $Recall = 0.29$ | $Accuracy = 0.86$

הסבר: צמצום ל-10 הפיצ'רים החשובים לפי SHAP שיפר מעט את הביצועים והגדיל את מספר מקרי ה-CAD שזוהו (מ-16 ל-24). עם זאת, הביצועים נותרו נמוכים בשל כמות קטנה מאוד של מקרים חיוביים (84 בלבד).

תובנה קלינית: חיזוי CAD מוקדם נותר אתגר מהנתונים הקיימים; המודל מספק אינדיקציה ראשונית בלבד וכדאי לשלבו עם שיקול קליני.

5.4 Early CHF — (אי-ספיקת לב)

א. הכנת הנתונים למודל זה

המודל אומן בגרסה מלאה ומצומצמת המבוססת על 10 הפיצ'רים המשפיעים ביותר לפי SHAP.


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (Threshold 50%)

ממד (Metric)	ערך (Value)
PR-AUC	0.1892
ROC-AUC	—
Recall (class 1)	0.55
Precision (class 1)	0.22
F1-Score (class 1)	0.32
Accuracy	0.89

מטריצת בלבול: TP=62 | FP=214 | FN=50 | TN=2097

ניתוח SHAP — הפיצ'רים המשפיעים ביותר



SHAP — early CHF: BL_CHF, Lab_Creat, Lab_Urea, BL_CAD, Lab_WBC ועוד

מודל 2 — XGBoost עם 10 פיצ'רים מובילים (SHAP, Threshold 50%)

ממד (Metric)	ערך (Value)
PR-AUC	0.1985
ROC-AUC	—
Recall (class 1)	0.56
Precision (class 1)	0.22
F1-Score (class 1)	0.32
Accuracy	0.89

מטריצת בלבול: TP=63 | FP=224 | FN=49 | TN=2087

ג. המודל הנבחר

✓ המודל הנבחר

המודל 2: XGBoost לאחר 10 — SHAP פיצ'רים

המדד המרכזי: $PR-AUC = 0.1985$ | $Recall = 0.56$ | $Accuracy = 0.89$

הסבר: גרסת 10 הפיצ'רים לפי SHAP שיפרה את ה- $PR-AUC$ (מ-0.1892 ל-0.1985) תוך שמירה על דיוק גבוה. הפיצ'ר הדומיננטי היה BL_CHF, בהתאם לציפייה הקלינית.

תובנה קלינית: המודל מזהה מעל מחצית ממקרי אי-ספיקת הלב ויכול לשמש לסימון מטופלים למעקב מוגבר לאחר הניתוח.

Early Paraplegia — 5.5

א. הכנת הנתונים למודל זה

מספר המקרים החיוביים בדאטה היה קטן ביותר (11 מטופלים בלבד), ולכן המודל התקשה מאוד ללמוד את הקבוצה המיעוטית. התוצאות מובאות לשם שלמות התמונה.


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (לפני SHAP)

מדד (Metric)	ערך (Value)
PR-AUC	0.005
ROC-AUC	0.464
Recall (class 1)	0.00
Precision (class 1)	0.00
F1-Score (class 1)	0.00
Accuracy	1.00

מטריצת בלבול: TP=0 | FP=0 | FN=11 | TN=2412

ניתוח SHAP — הפיצ'רים המשפיעים ביותר



early Paraplegia: SHAP — *Lab_albumin, Lab_Creat, Lab_Urea, Lab_WBC, Lab_HB*

מודל 2 — XGBoost (אחרי SHAP, פיצ'רים נבחרים)

ממד (Metric)	ערך (Value)
PR-AUC	0.006
ROC-AUC	0.553
Recall (class 1)	0.18
Precision (class 1)	0.01
F1-Score (class 1)	0.02
Accuracy	0.89

מטריצת בלבול: TP=2 | FP=246 | FN=9 | TN=2166

ג. המודל הנבחר

✓ המודל הנבחר

המודל 2: XGBoost לאחר SHAP

המדד המרכזי: ROC-AUC = 0.553 | PR-AUC = 0.006

הסבר: מבין שני המודלים, גרסה זו טובה יחסית (זיהתה 2 מתוך 11 מקרים לעומת 0 בגרסה הראשונה). עם זאת, בשל מיעוט קיצוני של מקרים חיוביים (11 בלבד), המודל אינו אמין לשימוש קליני ומובא לשם שלמות התמונה בלבד.

תובנה קלינית: כדי לבנות חיזוי אמין לפרהפלגיה נדרשת כמות נתונים גדולה בהרבה של מקרים חיוביים.

5.6 Early Reintervention — (התערבות חוזרת תוך 30 יום אחרי ניתוח ראשון)

א. הכנת הנתונים למודל זה

המודל אומן בגרסה מלאה ובגרסה לאחר בחירת פיצ'רים לפי SHAP, וכן נבדקו ANN ו- Ensemble.


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (Production, כל הפיצ'רים, Threshold 40%)

ממד (Metric)	ערך (Value)
PR-AUC	0.0463
ROC-AUC	—
Recall (class 1)	0.21
Precision (class 1)	0.06
F1-Score (class 1)	0.10
Accuracy	0.86

מטריצת בלבול: TP=18 | FP=274 | FN=68 | TN=2063

ניתוח SHAP — 20 הפיצ'רים המשפיעים ביותר



SHAP — early reintervention: cleaned_admission_diagnosis_UNKNOWN, bmi_comheight, Lab_WBC ועוד Lab_Creat

מודל 2 — XGBoost (אחרי SHAP, 15 פיצ'רים נבחרים)

ממד (Metric)	ערך (Value)
PR-AUC	0.061
ROC-AUC	0.569
Recall (class 1)	0.16
Precision (class 1)	0.05
F1-Score (class 1)	0.08
Accuracy	0.86

מטריצת בלבול: TP=14 | FP=269 | FN=72 | TN=2068

מודל 3 — ANN (SMOTE 20%, רשת (32,16), Threshold 30%)

ערך (Value)	מדד (Metric)
0.0625	PR-AUC
0.5890	ROC-AUC
0.29	Recall (class 1)
0.06	Precision (class 1)
0.10	F1-Score (class 1)
0.82	Accuracy

מטריצת בלבול: TP=25 | FP=384 | FN=61 | TN=1953

מודל 4 — Ensemble (XGBoost + ANN, 15) פיצ'רים מובילים

ערך (Value)	מדד (Metric)
0.0551	PR-AUC
0.6245	ROC-AUC
0.31	Recall (class 1)
0.06	Precision (class 1)
0.10	F1-Score (class 1)
0.80	Accuracy

מטריצת בלבול: TP=27 | FP=434 | FN=59 | TN=1903

הערה: בחירת הפיצ'רים לפי SHAP לא הביאה לשיפור משמעותי במודל early_reintervention.

ג. המודל הנבחר

✓ המודל הנבחר]

המודל 4: Ensemble (XGBoost + ANN)

המדד המרכזי: ROC-AUC = 0.6245 | PR-AUC = 0.0551 | Recall = 0.31 | Accuracy = 0.80

הסבר: שילוב XGBoost ו-ANN נתן את ה-ROC-AUC הגבוה ביותר עבור Target זה, ומנצל את היתרונות של שני המודלים יחד. עם זאת, הביצועים הכוללים מתונים, וכלל המודלים התקשו לחזות התערבות חוזרת מוקדמת.

תובנה קלינית: המודל מזהה כשליש ממקרי ההתערבות החוזרת המוקדמת; שימושי כסימון ראשוני אך לא כתחליף להערכה קלינית.

5.7 — Early Stroke (שבץ מוקדם)

עבור משתנה מטרה זה לא התקבלו תוצאות מספקות, בשל כמות קטנה מאוד של מקרים חיוביים (מספר השורות עם ערך 1, כלומר המטופלים שחוו שבץ, היה נמוך מאוד). בשל כך לא ניתן היה לאמן מודל אמין, והמשתנה לא נכלל בהשוואה הסופית.

5.8 Death up to 36 Months (מוות עד 36 חודשים)

א. הכנת הנתונים למודל זה

משתנה זה משלב מוות מוקדם ומוות מאוחר עד 36 חודשים. נבנו שני מודלים: מודל סיווג (XGBoost) ומודל הישרדות (Cox).


ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (סיווג, Death_Within_3Years)


ממד (Metric)	ערך (Value)
PR-AUC	0.4951
ROC-AUC	0.7599
Recall (class 1)	0.69
Precision (class 1)	0.39
F1-Score (class 1)	0.50
Accuracy	0.69

מטריצת בלבול: תמיכה: שרדו +3 שנים = 1888 | נפטרו תוך 3 שנים = 535


מודל 2 — Cox Proportional Hazards (Cox_Death_Up_To_36_Months)



20 — Forest Plot הפיצ'רים המובילים (Cox, Death)



Kaplan-Meier לפי קבוצת סיכון



עקומות ROC ו-Precision-Recall (Cox, Death)

ממד (Metric)	ערך (Value)
C-index	0.857
ROC-AUC	0.862
PR-AUC	0.337
Recall (בסך מיטבי F2=0.05)	0.864
Precision (בסך מיטבי)	0.154

ג. המודל הנבחר

✓ המודל הנבחר

המודל 2: Cox Proportional Hazards

המדד המרכזי: C-index = 0.857 | ROC-AUC = 0.862 | PR-AUC = 0.337

הסבר: בחרנו במודל Cox מכיוון שהוא מודל הישרדות (Survival) המתחשב בזמן עד האירוע ואינו בינארי ולכן מדויק יותר עבור חיזוי לאורך זמן מאשר מודל סיווג. המודל השיג C-index גבוה מאוד (0.857) המעיד על יכולת הפרדה מצוינת בין רמות סיכון.

תובנה קלינית: המודל מדרג מטופלים לפי סיכון למוות בתוך 36 חודשים, ומאפשר תעדוף מעקב ארוך-טווח והקצאת משאבים רפואיים.

5.9 Reintervention up to 36 Months (התערבות חוזרת עד 36 חודשים)

א. הכנת הנתונים למודל זה

משתנה זה משלב התערבות חוזרת מוקדמת ומאוחרת עד 36 חודשים. נבדקו מודל סיווג על כלל המטופלים, מודל סיווג על תת-קבוצת המנותחים ($Surgery=1$), ומודל הישרדות Cox. ההבדל בין שני סוגי הניתוחים היה קטן, ולכן התוצאה הנבחרת תהיה עם שני הניתוחים יחד.

ב. תוצאות מודל אחר מודל

מודל 1 — XGBoost (סיווג, כל המטופלים)

ערך (Value)	מדד (Metric)
0.1957	PR-AUC
0.5880	ROC-AUC
0.35	Recall (class 1)
0.19	Precision (class 1)
0.25	F1-Score (class 1)
0.69	Accuracy


מטריצת בלבול: TP=125 | FP=520 | FN=232 | TN=1546

מודל 2 — XGBoost (סיווג, תת-קבוצת $Surgery=1$)


ערך (Value)	מדד (Metric)
0.1844	PR-AUC
0.5557	ROC-AUC
0.34	Recall (class 1)
0.19	Precision (class 1)
0.25	F1-Score (class 1)
0.67	Accuracy

מטריצת בלבול: TP=116 | FP=482 | FN=222 | TN=1341 (n=2161)


מודל 3 — Cox Proportional Hazards (Late Reintervention)



Forest Plot — 20 הפיצורים המובילים (Cox, Reintervention)



Kaplan-Meier לפי קבוצת סיכון (אופק 36 חודשים)



עקומות ROC ו-Precision-Recall (Cox, Reintervention)

ממד (Metric)	ערך (Value)
C-index	0.630
ROC-AUC	0.640
PR-AUC	0.226
Recall (בסך מיטבי F2=0.1)	0.973
Precision (בסך מיטבי)	0.151

ג. המודל הנבחר

✓ המודל הנבחר

המודל 3: Cox Proportional Hazards

המדד המרכזי: C-index = 0.630 | ROC-AUC = 0.640 | PR-AUC = 0.226

הסבר: גם כאן בחרנו במודל Cox בזכות התחשבותו בזמן עד האירוע והיותו לא-בינארי. הוא השיג את ה-PR AUC וה-ROC AUC הגבוהים ביותר מבין שלושת המודלים, אם כי ביכולת הפרדה מתונה.

תובנה קלינית: המודל מספק דירוג סיכון להתערבות חוזרת עד 36 חודשים, לתמיכה בהחלטות מעקב לאחר הניתוח.

6. סיכום והשוואה

הטבלה הבאה מסכמת, עבור כל משתנה מטרה, את טווח המדדים המרכזיים שהתקבלו. עמודת "המודל הנבחר" תושלם לאחר בחירתך.

משתנה מטרה	מדד מרכזי (טווח)	המודל הטוב לפי הנתונים	המודל הנבחר
Early Death	PR-AUC 0.2708	ANN + Tuning	✓ ANN + Tuning
Early MACCE	ROC-AUC 0.71	SHAP אחרי XGBoost	✓ XGBoost + SHAP
Early CAD	PR-AUC 0.0594	XGBoost + SHAP (10)	✓ XGBoost + SHAP (10)
Early CHF	PR-AUC 0.1985	XGBoost + SHAP (10)	✓ XGBoost + SHAP (10)
Early Paraplegia	ROC-AUC 0.553	XGBoost + SHAP	XGBoost + SHAP (לא אמין)
Early Reintervention	ROC-AUC 0.6245	Ensemble	✓ Ensemble
Death up to 36M	C-index 0.857	Cox	✓ Cox
Reintervention 36M	C-index 0.630	Cox	✓ Cox

8. מסקנות

בפרויקט Aorta AI בנינו ובחנו מגוון מודלים של למידת מכונה לחיזוי סיכון לסיבוכים לאחר ניתוח אבי העורקים, עבור שמונה משתני מטרה שונים. התובנה המרכזית היא שאיכות החיזוי תלויה במידה רבה בשכיחות הסיבוך בנתונים: עבור סיבוכים שכיחים יחסית (כמו מוות עד 36 חודשים) השגנו ביצועים טובים מאוד, בעוד שעבור סיבוכים נדירים מאוד כמו Paraplegia ו Stroke לא ניתן היה לבנות מודל אמין.

מה עבד טוב: מבחינת המודלים, ראינו ששיטות שונות הצטיינו במשימות שונות. רשת הניורונים לאחר כיוונון היפר-פרמטרים נתנה את התוצאה הטובה ביותר עבור Early Death, ה Ensemble-Cox (XGBoost + ANN) הצטיין ב Early Reintervention ומודל ההישרדות Cox היה המתאים והמדויק ביותר עבור משתני המטרה בטווח הארוך Death ו Reintervention עד 36 חודשים, בזכות התחשבותו בזמן עד האירוע. השימוש ב SHAP-תרם משמעותית, הוא איפשר לזהות את הפיצ'רים החשובים ביותר, לצמצם את המודל, ולוודא שהוא לומד קשרים רפואיים הגיוניים.

הפיצ'רים המשפיעים ביותר: לאורך המשתנים השונים חזרו ובלטו אותם גורמי סיכון קליניים: רקע של אי-ספיקת לב (BL_CHF) ומחלת עורקים כליליים, (BL_CAD) רמות אלבומין (Lab_albumin), קריאטינין (Lab_Creat) ואוריאה, (Lab_Urea) וכן BMI וגיל. עובדה זו מחזקת את אמינות המודלים, שכן מדובר בגורמי סיכון מוכרים בספרות הרפואית, ומעידה שהמודל לומד דפוסים אמיתיים ולא רעש.

מגבלות: המגבלה המרכזית הייתה חוסר האיזון בנתונים (Imbalanced Data), מספר המטופלים שחוו סיבוך היה קטן בהרבה מאלו שלא, מה שהקשה על השגת Precision גבוה. עבור הסיבוכים הנדירים ביותר, מספר המקרים החיוביים היה קטן מכדי לאמן מודל בעל ערך קליני. בנוסף, חלק מהמשתנים (כמו CAD ו Reintervention מוקדם) נותרו קשים לחיזוי מהנתונים הקיימים בלבד.

כיווני המשך: לשיפור עתידי מומלץ להרחיב את מאגר הנתונים (במיוחד עבור הסיבוכים הנדירים), לשקול הוספת משתנים קליניים נוספים, ולבחון שיטות מתקדמות נוספות לטיפול בחוסר איזון. כמו כן, ניתן לשלב את המודלים ככלי תומך-החלטה (Decision Support) לצד שיקול הדעת הרפואי, ולא כתחליף לו.